Számítógépes szemantika

Vector Semantics and Embeddings

Ferenczi Zsanett

2020. április 24.

Vázlat

1. Bevezetés
2. Lexikális szemantika
3. Szavak és vektorok
4. Vektorok hasonlósága
5. tf-idf
6. PPMI
7. Skip-gram
8. A szóbeágyazások szemantikai jellemzői
9. Vektoros modellek kiértékelése

Bevezetés

Bevezetés

- a szavakat ábrázolhatjuk atomi elemekként, de így elveszítjük a kapcsolatokat közöttük
- szavak hasonlósága fontos bizonyos feladatok esetén
- ötlet: a szavakat próbáljuk **jelentésük** alapján kódolni, ezáltal a hasonlóság is megragadható lesz két szó között
- 1950-es évek: `disztribúciós hipotézis`: a szinonimák gyakran hasonló környezetben fordulnak elő
- pl. *oculist* és *eye-doctor* gyakran állnak együtt az *eye*, *examined* szavakkal

$\rightarrow$ a hasonló környezetben álló szavak hasonló jelentéssel bírnak

Egy példa

Tesgüino?

A bottle of **tesgüino** is on the table
Everybody likes **tesgüino**
Tesgüino makes you drunk
We make **tesgüino** out of corn.

"You shall know a word by the company it keeps!" (Firth (1957))

Lexikális szemantika

Lexikális szemantika

egér (*főnév*)

1. nagy szemű és fülű, hegyes orrú rágcsáló...
2. számítógép kézi vezérlőeszköze...

- `lemma (címszó)`: egér
- `szóalakok`: egér, egerek, egérnek, stb.
- `jelentés (word sense)`: itt a két definíció adja meg az egyes jelentéseket
- `poliszémia`: egy szónak több jelentése van $\rightarrow$ jelentés egyértelműsítés (`WSD`)

Kapcsolatok

- `szinonímia`: egyik szó jelentése közel azonos egy másik szó jelentésével
- `hasonlóság (word similarity)`: szavak között állhat fenn, pl. *kutya* és *macska*
- `word relatedness`: szavak közötti egyéb kapcsolat
  pl. *kórház* és *sebész*
  ilyen még: `hiperonímia`, `antonímia`, `meronímia` (ld. 19. fejezet)
- `szemantikai keret, szerepek`: olyan szavak, szereplők halmaza, melyek egy eseményhez köthetők
- `konnotáció`: pl. negatív konnotáció: *szomorú*, pozitív konnotáció: *boldog*

Vector Semantics

	Valence	Arousal	Dominance
courageous	8.05	5.5	7.38
music	7.67	5.57	6.5
heartbreak	2.45	5.65	3.58
cub	6.71	3.95	4.24
life	6.68	5.59	5.89

- egy szó jelentése ábrázolható pontként a térben (Osgood et al. (1957))
- hasonló környezetben előforduló szavak hasonló jelentésűek (egy szó ábrázolása a körülötte előforduló szavak számlálásával)
- ezen két megfigyelést ötvözi a vector semantics
- `szóbeágyazás`: olyan vektor, amely egy szót reprezentál

Szavak és vektorok

Szavak és vektorok

- a vektorok általában együttes előfordulási mátrixon alapulnak (co-occurence matrix)
- pl. `term-document matrix`: minden sor egy szót jelöl, minden oszlop egy dokumentumot
- `V. Henriket` a `[13, 89, 4, 3]` vektorral lehetne ábrázolni
- a vektortér dimenziója ebben az esetben 4

	As You Like It	Twelfth Night	Julius Caesar	Henry V
battle	1	0	7	13
good	114	80	62	89
fool	36	58	1	4
wit	20	15	2	3

Vektorok

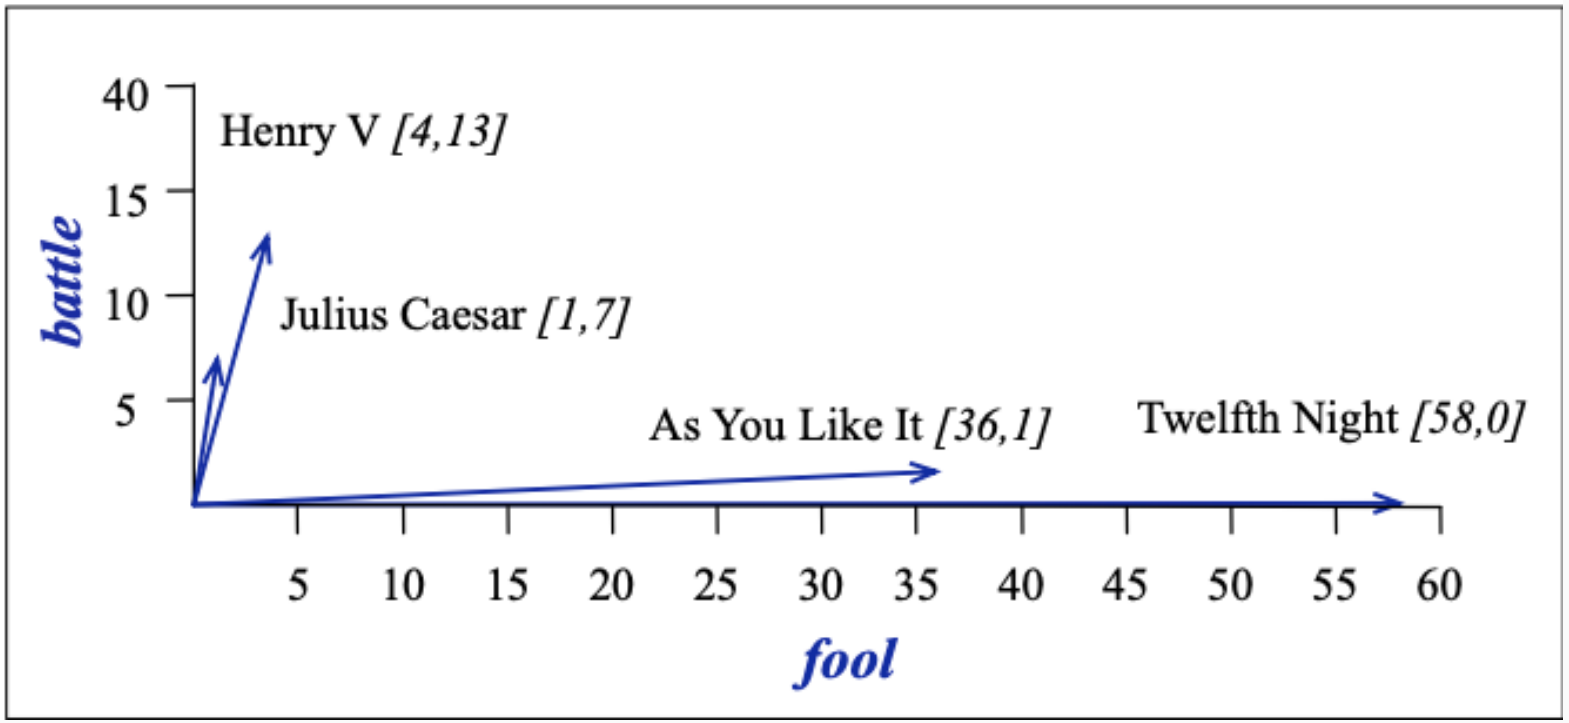

- Shakespeare 4 darabja két dimenzión ábrázolva (4 dokumentumvektor)
- egy term-document mátrix annyi dimenziós lenne, ahány type van a dokumentumokban ($|V|$ sor)

Term-term mátrix

- `term-term (word-word vagy term-context) mátrix`:
  sorok és oszlopok is szavakat jelölnek
- a dimenziója: $|V| \times |V|$ (a $|V|$ általában 10 000 és 50 000 közötti)
- sor: `célszó` (target word), oszlop: `kontextus(szavak)`
- az egyes cellák azt jelölik, hogy a célszó hányszor fordult elő a kontextusszó környezetében
- a környezet lehet egy dokumentum, de lehet kisebb egység is, pl. a szó körüli `ablak` (a célszótól jobbra és balra 4-4 szó)

	aardvark	...	computer	data	result	pie	sugar	...
cherry	0	...	2	8	9	442	25	
strawberry	0	...	0	0	1	60	19	
digital	0	...	1670	1683	85	5	4	
information	0	...	3325	3982	378	5	13	

Vektorok hasonlósága

Vektorok hasonlósága

- két vektor közötti hasonlóság mérése → `skaláris szorzattal`
- nagy lesz, ha két vektor ugyanazon dimenzióinak értékei nagyok
- 0 pedig, ha egyáltalán nem hasonlóak

$$\textit{dot product}(\mathbf{v}, \mathbf{w}) = \mathbf{v} \cdot \mathbf{w} = \sum_{i=1}^{N} v_i w_i = v_1 w_1 + v_2 w_2 + ... + v_N w_N$$

Vektorok hasonlósága

- a skaláris szorzat előnyben részesíti a hosszabb vektorokat, így a gyakoribb szavak magasabb értékeket kapnak, míg a kevésbé gyakori szavakhoz nehéz hasonlót találni → ez probléma
- egy megoldás: elosztjuk a vektorok hosszával → `a bezárt szög koszinusza` (0 és 1 közötti szám)
- vektor hossza:

$$|\mathbf{v}| = \sqrt{\sum_{i=1}^{N} v_i^2}$$

$$\frac{\mathbf{a} \cdot \mathbf{b}}{|\mathbf{a}||\mathbf{b}|} = cos\theta$$

Vektorok hasonlósága

	pie	data	computer
cherry	442	8	2
digital	5	1683	1670
information	5	3982	3325

$$\cos(\text{cherry}, \text{information}) = \frac{442*5+8*3982+2*3325}{\sqrt{442^2+8^2+2^2}\sqrt{5^2+3982^2+3325^2}} = .017$$

$$\cos(\text{digital}, \text{information}) = \frac{5*5+1683*3982+1670*3325}{\sqrt{5^2+1683^2+1670^2}\sqrt{5^2+3982^2+3325^2}} = .996$$

tf-idf

tf-idf

- a sokszor együtt előforduló szavak fontosabbak, mint a csak néhányszor előfordulók
- de a túl gyakori szavak nem lényegesek: a `good` minden dokumentumban nagyjából ugyanannyiszor fordul elő (ld. 7. dia)
- ezt egyensúlyozni kell → `tf-idf algoritmus`
- `term frequency (tf)`: $tf_{t,d}$ = t szó gyakorisága d dokumentumban

$$tf_{t,d} = \log_{10}(count(t,d) + 1)$$

$$tf_{t,d} = \frac{count(t,d)}{|D|}$$

tf-idf

	Collection Frequency	Document Frequency
Romeo	113	1
action	113	31

- `document frequency (df)`: df_t = hány dokumentumban fordul elő t szó
- `collection frequency`: t szó hányszor fordul elő összesen a dokumentumokban
- az olyan szavak, mint a `Romeo` kihangsúlyozása `idf`-fel
- `inverse document frequency (idf)`: a kevesebb dokumentumban előforduló szavak előnyben részesítése (`N` = dokumentumok száma)

$$idf_t = \log_{10}\left(\frac{N}{df_t}\right)$$

tf-idf

- a `tf-idf` ezek szorzata:

$$w_{t,d} = tf_{t,d} \times idf_t$$

- `tf-idf model`:
  - célszó vektorként való ábrázolása
  - annyi dimenzióval, ahány szó van a dokumentumban
  - minden dimenzión azt jelölve, hányszor fordult elő az adott szóval
  - `tf-idf`-fel súlyozva
  - szavak hasonlósága: `tf-idf` vektorok koszinusza

	As You Like It	Twelfth Night	Julius Caesar	Henry V
battle	0.074	0	0.22	0.28
good	0	0	0	0
fool	0.019	0.021	0.0036	0.0083
wit	0.049	0.044	0.018	0.022

PPMI

PMI

- `PMI (pointwise mutual information)`: annak mértéke, hogy két esemény milyen gyakran következik be, azzal összevetve, hogy mire számítanánk, ha egymástól függetlenek lennének
- `w` - célszó, `c` - kontextus(szó)

$$PMI(w, c) = \log_2 \frac{P(w, c)}{P(w)P(c)}$$

- ez $-\infty$ és $+\infty$ közötti eredményt ad
- ahhoz, hogy valami kevesebbszer forduljon elő, mint várnánk, hatalmas korpusz kellene $\rightarrow$ `Positive PMI`
- minden negatív értéket 0-ra cserélünk

$$PPMI(w, c) = \max(\log_2 \frac{P(w, c)}{P(w)P(c)}, 0)$$

Skip-gram

Skip-gram

- a vektorok eddig hosszúak és ritkák (sok elem 0) voltak
- másik metódus: rövidebb (50-1000) és sűrűbb vektorok → `skip-gram with negative sampling`
- ez a `word2vec` egyik algoritmusa
- ennek módja:
  - a célszót és a környezetét kezeljük pozitív mintaként
  - válasszunk random szavakat a lexikonból (negatív minták)
  - logisztikus regresszió használata a betanításhoz
  - regressziós súlyok használata szóbeágyazásokként
- a skip-gram probabilisztikus osztályozója: `t` célszó és `k` méretű ablak esetén $\mathbf{c}_{1:k}$ kontextus mennyire hasonlít a `t` szóhoz

Skip-gram

$$P(+|t,c) = \frac{1}{1+e^{-t\cdot c}}$$

$$P(-|t,c) = 1 - P(+|t,c)$$

$$P(+|t,c_{1:k}) = \prod_{i=1}^{k} \frac{1}{1+e^{-t\cdot c_i}}$$

Skip-gram szóbeágyazások tanulása

```
... lemon,  a [tablespoon of apricot jam,      a] pinch ...
              c1         c2    t     c3       c4
```

positive examples +

t	c
apricot	tablespoon
apricot	of
apricot	jam
apricot	a

negative examples -

t	c	t	c
apricot	aardvark	apricot	seven
apricot	my	apricot	forever
apricot	where	apricot	dear
apricot	coaxial	apricot	if

- kétszer annyi negatív mintát használ, mint pozitívat
- kell egy kiinduló szóbeágyazás-halmaz
- ezek segítségével maximalizálni kell a pozitív minták hasonlóságát és minimalizálni a negatív minták hasonlóságát

$$L(\theta) = \sum_{(t,c)\in+} \log P(+|t,c) + \sum_{(t,c)\in-} \log P(-|t,c)$$

Skip-gram

- minden szóhoz két különböző vektort tanul meg: amikor `t` célszó, vagy amikor `c` kontextusszó
- két mátrixban vannak ezek tárolva: T `target matrix`, és C `context matrix`
- 3 lehetőség:
  - csak a T-t tartjuk meg
  - összeadunk minden (d-dimenziós) vektort $\rightarrow$ új d-dimenziós vektor
  - konkatenáljuk őket $\rightarrow$ új 2d-dimenziós vektor
- az L ablak mérete befolyásolja a teljesítményt: devseten lehet finomhangolni

A szóbeágyazások szemantikai jellemzői

A szóbeágyazások szemantikai jellemzői

- `az ablak mérete`: általában 3 és 20 közötti (1-10 mindkét oldalon)
  - ha kisebb, inkább szintaktikai hasonlóságot mutatnak (pl. szófaj megegyezik)
  - ha nagyobb, témában hasonlóak
- pl. `Hogwarts`hoz leghasonlóbb szavak (Levy és Goldberg (2014))
  - ± 2 ablakkal: Evernight, Sunnydale, Collinwood, stb.
  - ± 5-össel: Dumbledore, half-blood, Malfoy, stb.
- `first-order co-occurence`: tipikusan közel állnak egymáshoz, pl. *wrote*, *book*
- `second-order co-occurence`: hasonló szomszédjaik vannak, pl. *wrote*, *said*

A szóbeágyazások szemantikai jellemzői

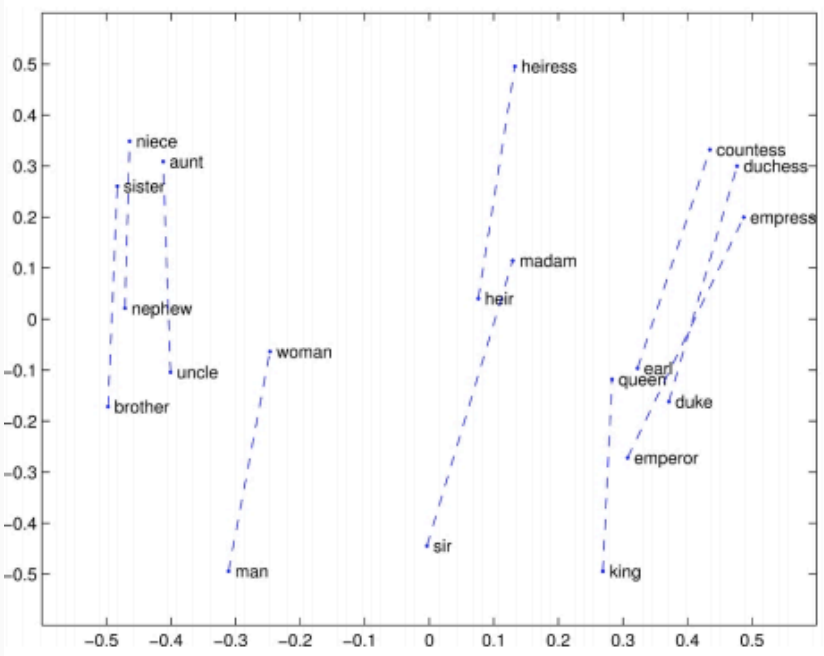

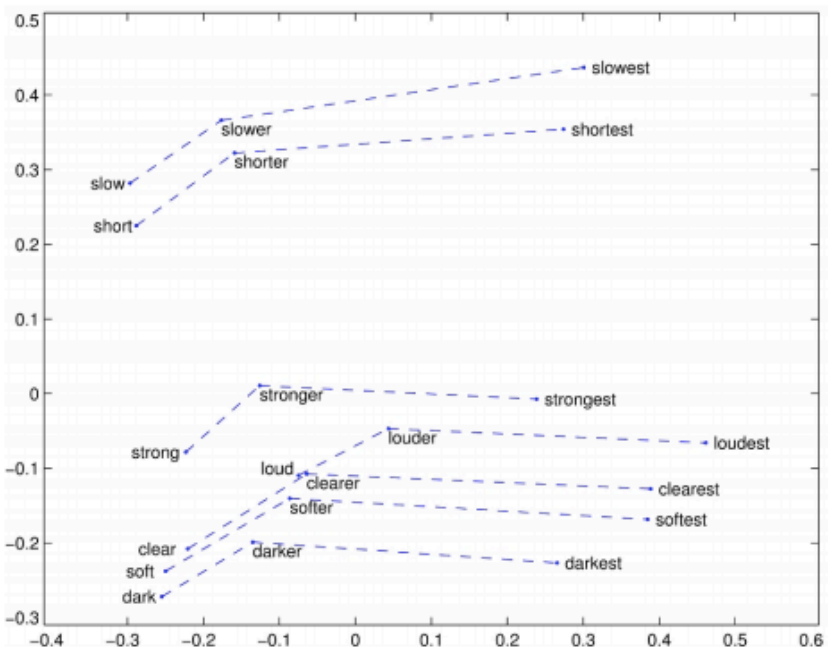

- `analógia`: az egyes vektorok közötti eltolások mintha valamilyen jelentéssel bírnának
- `történeti szemantika`: hogyan változott a jelentése egy szónak

Vektoros modellek kiértékelése

Kiértékelés

- `extrinsic` (beépítve más NLP feladatokba)
- `intrinsic`
  - hasonlóság mérése, összevetve egy gold standarddel
  - kontextus nélkül:
    → **WordSim-353** (0-10-es skálán 353 főnévpárt osztályoztak)
    → **SimLex-999** (melléknevek, igék, főnevek)
    → **TOEFL dataset** (80 kérdés, 4 lehetséges válasszal)
  - kontextussal:
    → **Stanford Contextual Word Similarity** (SCWS) dataset (2 003 szópár mondatba illesztve)
    → **Word-in-Context dataset** (egy célszó két kontextusban való megadása, el kell dönteni, hogy azonos jelentésben szerepel-e)

Egyéb szóbeágyazásos algoritmusok

- `GloVe`: valószínűségek arányát használja fel
- `fasttext`:
  - a word2vec kiterjesztése
  - kezeli az ismeretlen szavakat és ezáltal a gazdag morfológiájú nyelveket
  - minden szó saját maga és a benne megtalálható n-gramok alapján van reprezentálva

Bibliográfia

John R Firth. A synopsis of linguistic theory, 1930-1955. *Studies in linguistic analysis*, 1957.

Daniel Jurafsky and James Martin. *Speech and Language Processing: An Introduction to Natural Language Processing, Computational Linguistics, and Speech Recognition*, volume 3.

Omer Levy and Yoav Goldberg. Dependency-based word embeddings. In *Proceedings of the 52nd Annual Meeting of the Association for Computational Linguistics (Volume 2: Short Papers)*, pp. 302–308, 2014.

Charles Egerton Osgood, George J Suci, and Percy H Tannenbaum. *The measurement of meaning*. Number 47. University of Illinois press, 1957.